

2. METODE PENELITIAN


2.1 Sumber dan Karakteristik Data

Dataset yang digunakan dalam penelitian ini adalah dataset *data_titanic* dan dataset *data_prediksi*, diperoleh dari *link* Google Drive di folder data UAS. Dataset dalam set pelatihan (*data_titanic*) mencakup 891 penumpang, masing-masing diberi label untuk status keselamatannya. Setiap penumpang dikaitkan dengan beberapa atribut, yaitu nama, jenis kelamin, usia, kelas tiket, jumlah saudara kandung atau pasangan di dalam Titanic, jumlah orang tua atau anak di dalam kapal, nomor kabin, nomor tiket, tarif tiket, dan pelabuhan keberangkatan. Untuk set pengujian, yaitu *data_prediksi* mencakup 418 penumpang. Kedua dataset disediakan dalam format *xlsx*. Set data terdiri dari 12 fitur (*data_prediksi* tanpa kolom *Survived*) disajikan pada Tabel 1.

Tabel 1. Deskripsi dan tipe data pada masing-masing fitur dataset

Variabel	Deskripsi	Tipe Data	Variabel	Deskripsi	Tipe Data
Survived	Status keselamatan (0 = Tidak Selamat, 1 = Selamat)	Biner (Target)	PassengerId	Identitas (ID) penumpang	Integer (Identitas)
Pclass	Kelas penumpang (1, 2, 3)	Kategorik	Name	Nama penumpang	Object (Identitas)
Sex	Jenis kelamin penumpang	Kategorik	Ticket	Nomor tiket	Kategorik (Identitas)
Age	Usia penumpang	Numerik	Cabin	Nomor cabin	Kategorik
SibSp	Jumlah saudara kandung atau pasangan di kapal Titanic	Numerik	Parch	Jumlah orang tua atau anak di kapal Titanic	Numerik
Fare	Harga tiket penumpang	Numerik	Embarked	Pelabuhan keberangkatan (C=Cherbourg; Q=Queenstown; S=Southampton)	Kategorik

2.2 Tahapan Penelitian



Gambar 1. Diagram Alir Tahapan Penelitian

Penelitian ini menggunakan Python yang terdiri dari beberapa tahap analisis. Tahap awal adalah Pengumpulan Data, di mana dataset *data_titanic.xlsx* sebagai data pelatihan yang berlabel, dan *data_prediksi.xlsx* sebagai data pengujian tanpa label. Dilakukan Analisis Eksploratif Data (EDA) untuk mengidentifikasi pola dan karakteristik penumpang yang memengaruhi keselamatan. Selanjutnya, *Pre-processing Data*, meliputi seleksi fitur, seperti penghapusan variabel *PassengerId*, *Name*, dan *Ticket* karena bersifat identitas atau kode unik, kemudian penanganan *missing value* dengan menghapus variabel *Cabin* karena nilai hilang lebih dari 50% yang dapat menimbulkan bias apabila dilakukan imputasi, serta melakukan imputasi pada variabel numerik (*Age* dan *Fare*) dengan median dan imputasi dengan modus pada variabel kategorik (*Embarked*). Transformasi data dilakukan pada variabel kategorik (*Sex* dan *Embarked*) menjadi bentuk numerik melalui encoding.

Selanjutnya, setelah data siap dianalisis, dataset dibagi menjadi 80% *data training* dan 20% *data testing*. Tahap Pemodelan dilakukan dengan menerapkan dua algoritma *Supervised Learning*, yaitu *Logistic Regression* dan *Decision Tree*. Untuk memastikan model klasifikasi memiliki performa yang stabil dan akurat, kedua kinerja model diukur melalui tahap Evaluasi Model menggunakan K-Fold Cross Validation dengan $k = 5$, serta metrik evaluasi atau *confusion matrix* untuk menentukan model yang paling stabil dan akurat. Model terbaik yang terpilih akan digunakan dalam tahap Prediksi untuk menghasilkan label keselamatan pada data uji, lalu terakhir penarikan kesimpulan.

2.3 Metode Pemodelan

Penelitian ini menggunakan dua metode *supervised learning* untuk klasifikasi, yaitu *Logistic Regression* dan *Decision Tree*. Kedua metode tersebut mampu menangani permasalahan klasifikasi biner untuk analisis keselamatan penumpang Titanic.

2.3.1 *Logistic Regression*

Logistic Regression merupakan algoritma klasifikasi statistik yang dirancang untuk memprediksi probabilitas variabel target yang bersifat kategorikal biner. Berbeda dengan regresi linear yang memprediksi nilai kontinu, regresi logistik menggunakan fungsi sigmoid (logistik) untuk memetakan hubungan antara satu atau lebih fitur independen (prediktor) menjadi nilai peluang yang berada dalam rentang 0 hingga 1. Dalam konteks penelitian ini, algoritma ini menggunakan `LogisticRegression` untuk memodelkan pengaruh karakteristik penumpang terhadap kemungkinan keselamatan. Nilai probabilitas yang dihasilkan kemudian dikonversi menjadi kelas biner (0 untuk tidak selamat, 1 untuk selamat). Pemilihan regresi logistik didasarkan pada efisiensinya dalam klasifikasi dua kelas, kemudahan dalam menginterpretasi koefisien untuk melihat fitur mana yang paling berpengaruh, serta stabilitasnya sebagai model *baseline* yang sangat kuat untuk pengujian awal.

2.3.2 *Decision Tree*

Decision Tree adalah metode pembelajaran terbimbing (*supervised learning*) yang bekerja dengan cara membagi kumpulan data secara berulang menjadi himpunan bagian lebih kecil berdasarkan kriteria fitur paling informatif. Proses ini membentuk struktur hierarkis yang menyerupai pohon, terdiri dari simpul akar (*root node*), simpul internal (*internal node*) sebagai titik keputusan, dan simpul daun (*leaf node*) yang merepresentasikan hasil prediksi akhir.

Algoritma ini menggunakan `DecisionTreeClassifier` dengan ukuran *Gini Impurity* atau *Entropy* untuk menentukan fitur mana yang paling efektif dalam memisahkan data. Keunggulan utama *Decision Tree* dalam penelitian ini adalah kemampuannya untuk menangkap hubungan non-linear dan interaksi antarvariabel tanpa memerlukan asumsi distribusi data tertentu. Selain itu, model ini dapat divisualisasikan dengan jelas, sehingga mempermudah dalam menjelaskan penumpang diklasifikasikan selamat atau tidak selamat berdasarkan karakteristiknya.

2.4 Evaluasi Model

2.4.1 Validasi Model (K-Fold Cross Validation)

Dalam penelitian ini, validasi model dilakukan menggunakan K-Fold Cross Validation dengan nilai $k = 5$ (5 bagian atau *fold* sama besar). Proses pelatihan dan pengujian dilakukan sebanyak 5 kali secara bergantian, di mana pada setiap iterasi, empat bagian data digunakan sebagai data latih (*training set*) dan satu bagian lainnya digunakan sebagai data uji (*testing set*). Tujuan penggunaan K-Fold adalah untuk memperoleh estimasi performa model yang lebih stabil, mengurangi risiko *overfitting*, serta memastikan hasil akurasi tidak bergantung pada pembagian data secara acak. Hasil akhir dari validasi ini adalah nilai rata-rata (*mean*) dan standar deviasi (*standard deviation*) dari akurasi yang diperoleh pada setiap lipatan (*fold*).

2.4.2 Evaluasi Model

Model yang dikembangkan dievaluasi menggunakan beberapa metrik utama, yaitu akurasi, presisi, recall, dan F1-score, di mana TP (*True Positive*), TN (*True Negative*), FP (*False Positive*), dan FN (*False Negative*), serta evaluasi berdasarkan Kurva ROC-AUC dengan menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate* (FPR) pada berbagai ambang batas.

Tabel 2. *Confusion matrix*

<i>Correct Classification</i>	<i>Classified As</i>	
	<i>Predicted (+)</i>	<i>Predicted (-)</i>
<i>Actual (+)</i>	<i>True Positives</i>	<i>False Negatives</i>
<i>Actual (-)</i>	<i>False Positives</i>	<i>True Negatives</i>

Akurasi (*Accuracy*) mengukur kinerja model berdasarkan persentase prediksi yang dilakukan dengan benar terhadap seluruh data pengujian.

$$Accuracy = \frac{TN + TP}{TN + FP + FN + TP}$$

Presisi mengukur proporsi pengamatan aktual yang diprediksi dengan benar.

$$Precision = \frac{TP}{TP + FP}$$

Recall mengukur proporsi kasus positif yang benar diprediksi positif.

$$Recall = \frac{TP}{TP + FN}$$

F1-score adalah rata-rata harmonik dari *precision* dan *recall*.

$$F1\ score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$